基于时空选择和置信度反馈的车载网络入侵检测研究

答辩人：**李宏宇** | 指导老师：**王一丰**

2025.5.19

目录

1 研究介绍

2 方案详解

3 实验

4 总结

• 研究背景

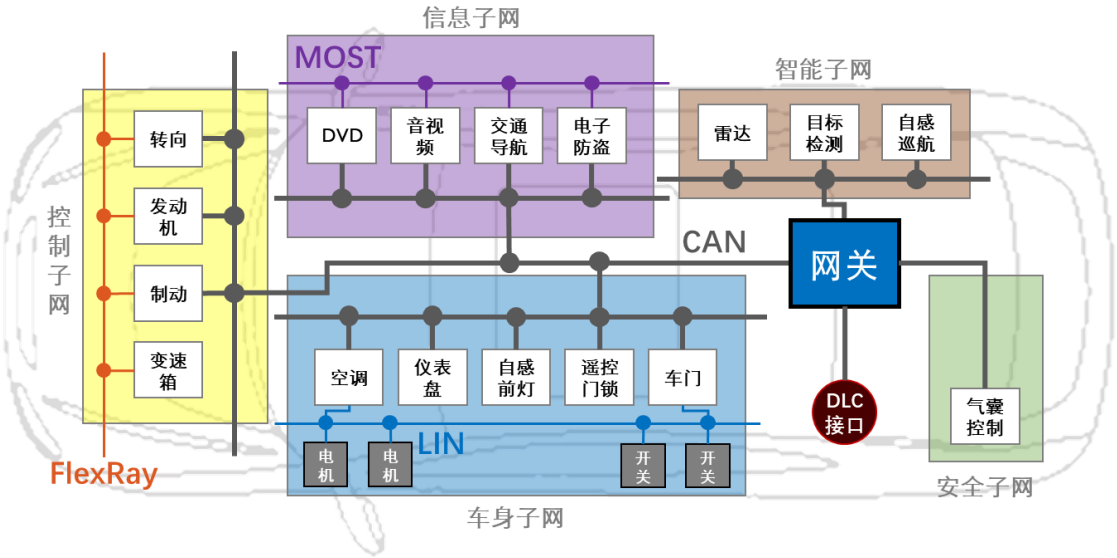

基于CAN总线的车载网络关键结构

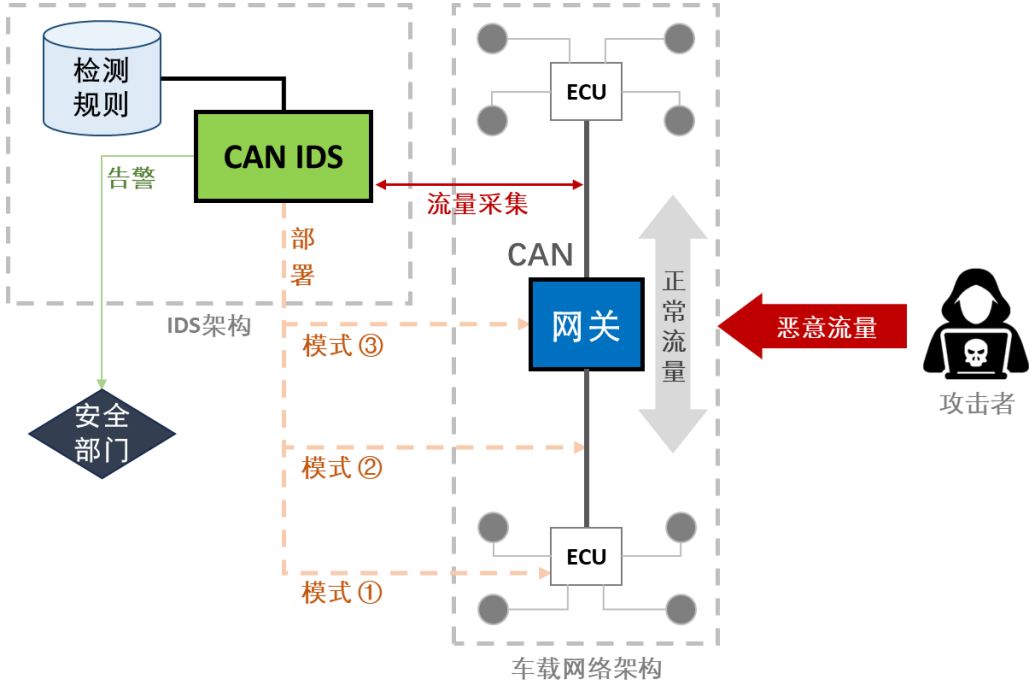

车载网络IDS机制

• 现有方案的不足 & 研究动机

现有不足

① 多尺度特征未有效建模

大部分深度学习IDS不能很好地处理CAN流量时序和空间特征的关联性，容易为特征分配不合理的权重

② 对CAN网络环境可见性不足

传统训练架构的IDS对数据结构性特征的学习程度不够，导致检测性能下降 (如稀有攻击检测)

③ 检测结果在决策侧不可信

深度学习IDS容易出现误报，且缺乏对检测依据的解释性指标，加剧了安全人员对IDS的不信任

创新思路

① 设计一种灵活的时空特征提取与融合方案

表征CAN流量在时序上的依赖性并整合到空间特征中，并对时空特性进行赋权

② 使用并优化“预训练-微调”的训练架构

促进模型学习数据模式，并优化算法提升微调分类任务的效果

③ 设计一种可解释的检测器

借助合适的方法提高模型对自身预测的信任，并通过提供尽可能多的见解提高安全人员对IDS决策的信任

• 论文结构

第2章
提出问题
传统CAN协议的安全挑战
CAN流量IDS研究现状
技术概述
分析问题
CAN流量异常表示
检测结果可信性
对CAN流量能见度
第3章
数据表征
可预测框架构建
训练架构优化
方案介绍
解决问题
第4章
验证结果
对比实验
消融实验
可解释性分析
实验分析
第5章
归纳总结
总结展望

论文组织结构

SCANet

Spatiotemporal Selection & **C**onfidence Feedback -based IDF for **CAN Net**work

时空选择 置信度反馈 CAN流量IDS框架

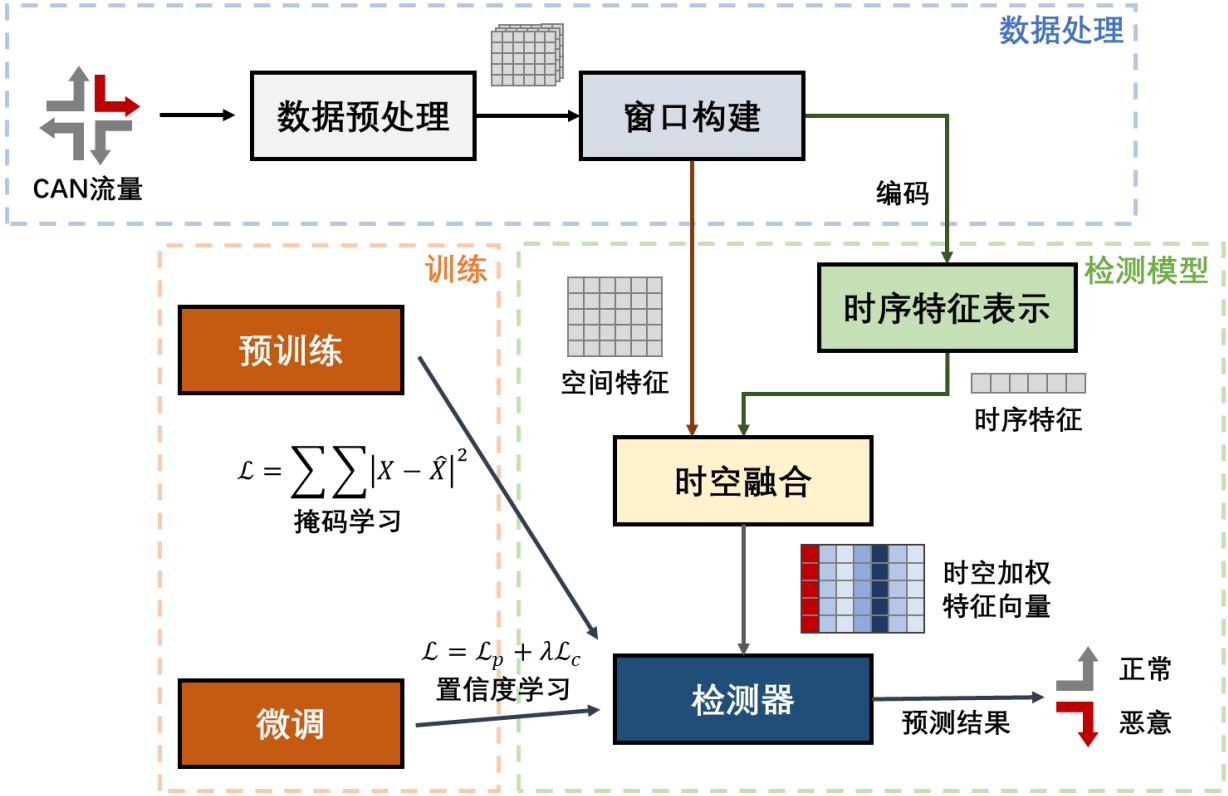

SCANet基础算法流程

- 基于滑动窗口的时隙分割策略
- 基于CNN-LSTM架构的时序特征表示与时空融合
- 基于TabNet的可解释检测与预训练机制
- 基于置信度反馈的微调训练机制

• 时序特征表示与时空融合

- **任务：**对时序特征编码，并对时空特征进行初步选择
- **组成：**
  - **时序编码器**：CNN+LSTM
    (增强局部表征，捕捉长期依赖关系)

$$v_{tem} = f_{enc}(x_{seq})$$

  - **特征融合**：注意力机制
    (捕捉时空特征的关联性，并赋权)

$$w_{att} = \sigma\left(f_{att}(v_{tm}, v_{sp})\right)$$

$$v_{WF} = \mathrm{concat}(w_{att} \cdot v_{tm}, (1 - w_{att}) \cdot W_{sp} v_{sp})$$

    - w_{att} 可解释选择时空重要性

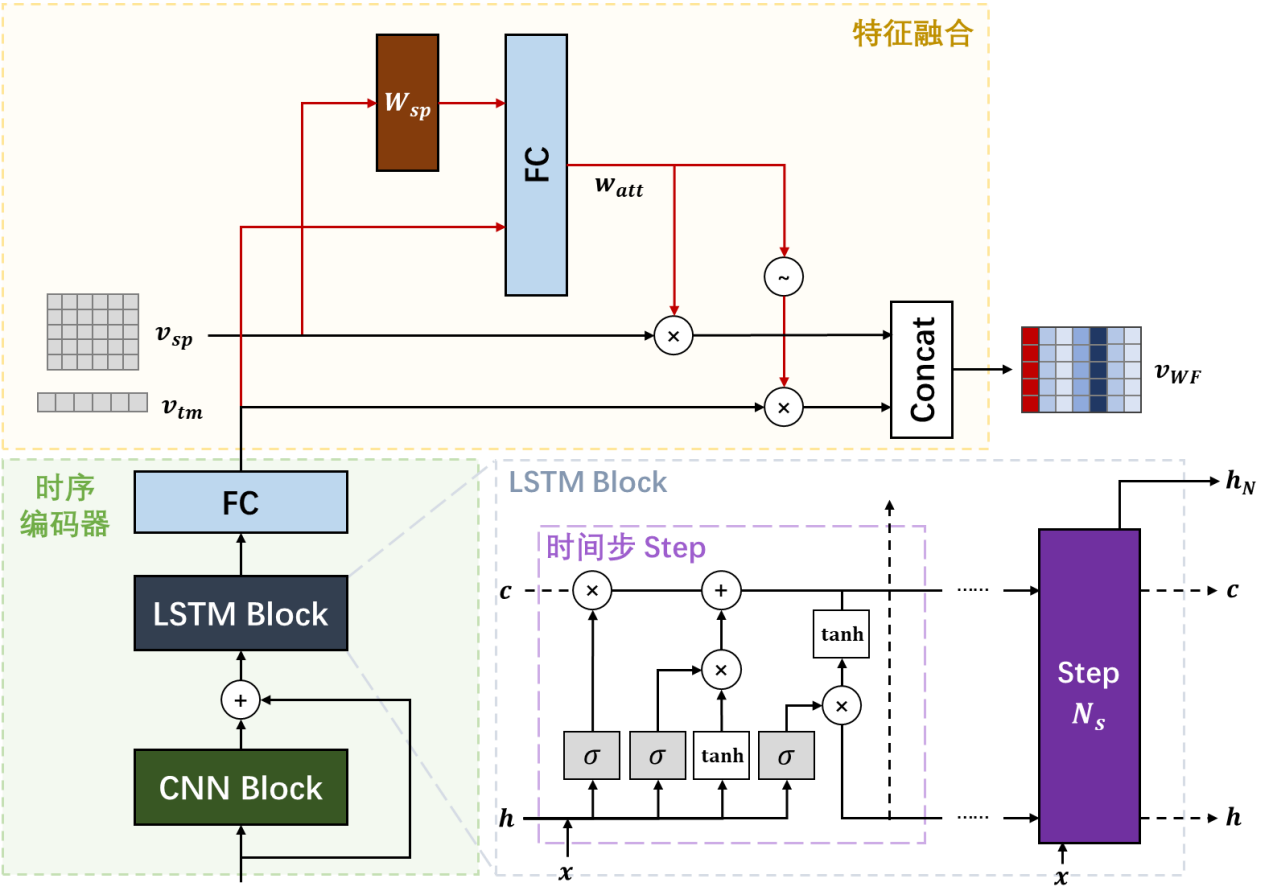

时序编码器与时空特征融合

• 检测机制

- **任务：**实现IDS的检测逻辑，并输出可解释性的指标
- **方案：**深度表格学习模型TabNet编码器架构
  (由多个决策步组成的决策流形，支持可解释性输出)
- **组成：**
  - **Attentive Transformer**：
    在当前决策筛选重点特征处理
  - **Feature Transformer**：
    对输入特征执行增强处理
  - **概率头 & 置信度头**：
    - 输出概率 p
    - 置信度 c：表征输出可信度；矫正预测
- **可解释输出：**特征重要性掩码矩阵

$$M_{agg-b,j} = \frac{\sum_{i=1}^{N_s} \eta_b[i] M[i]_{b,j}}{\sum_{j=1}^{D} \sum_{i=1}^{N_s} \eta_b[i] M[i]_{b,j}}$$

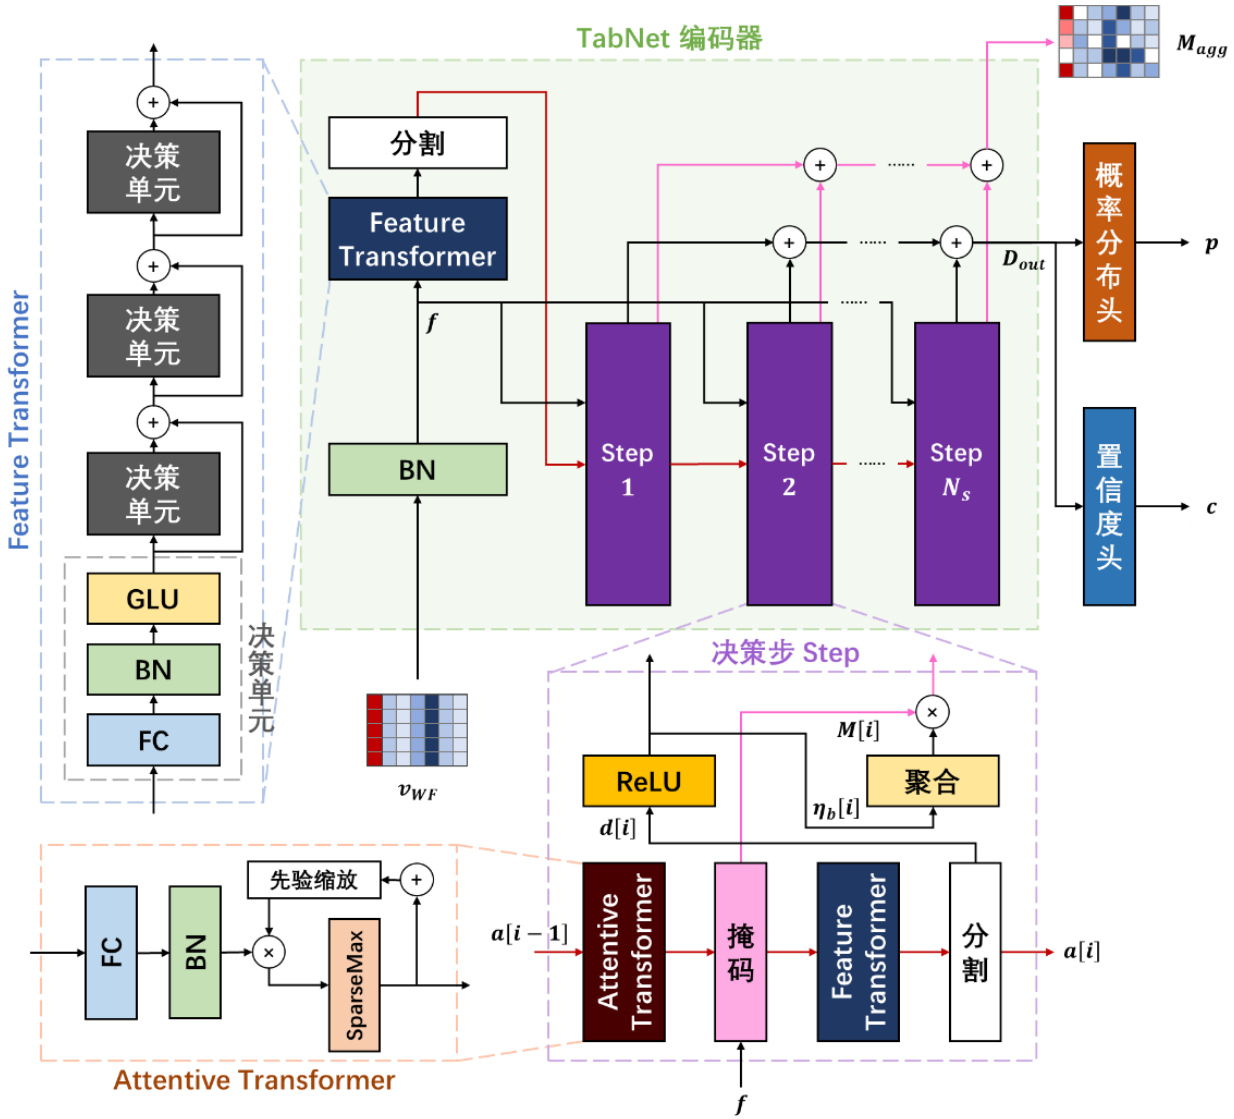

基于TabNet编码器的检测机制

• 预训练-微调

- **基于特征掩码的预训练：**
  - **任务：** 编-解码器架构掩码训练，执行特征重建
  - **目标：** 重建损失

$$\mathcal{L} = \sum_{b=1}^{B} \sum_{j=1}^{D} \left| \frac{(\hat{f}_{b,j} - f_{b,j}) \cdot S_{b,j}}{\sqrt{\sum_{b=1}^{B} \left(f_{b,j} - \frac{1}{B} \sum_{b=1}^{B} f_{b,j} \right)^2}} \right|^2$$

  - **训练数据：** 正常CAN流量

- **基于置信度反馈的微调训练：**
  - **任务：** 建立置信度惩罚机制，训练前期加速收敛，训练后期关注模型预测的可信程度
  - **目标：** 分类损失+置信度损失 (衰减加权)

$$\mathcal{L} = \mathcal{L}_p + \lambda \mathcal{L}_c = \sum_{i=1}^{n_c} -y_i \log(p_i') + \lambda(-\log(c))$$

$$\lambda = \lambda_0 \cdot e^{-\frac{s}{\beta}}$$

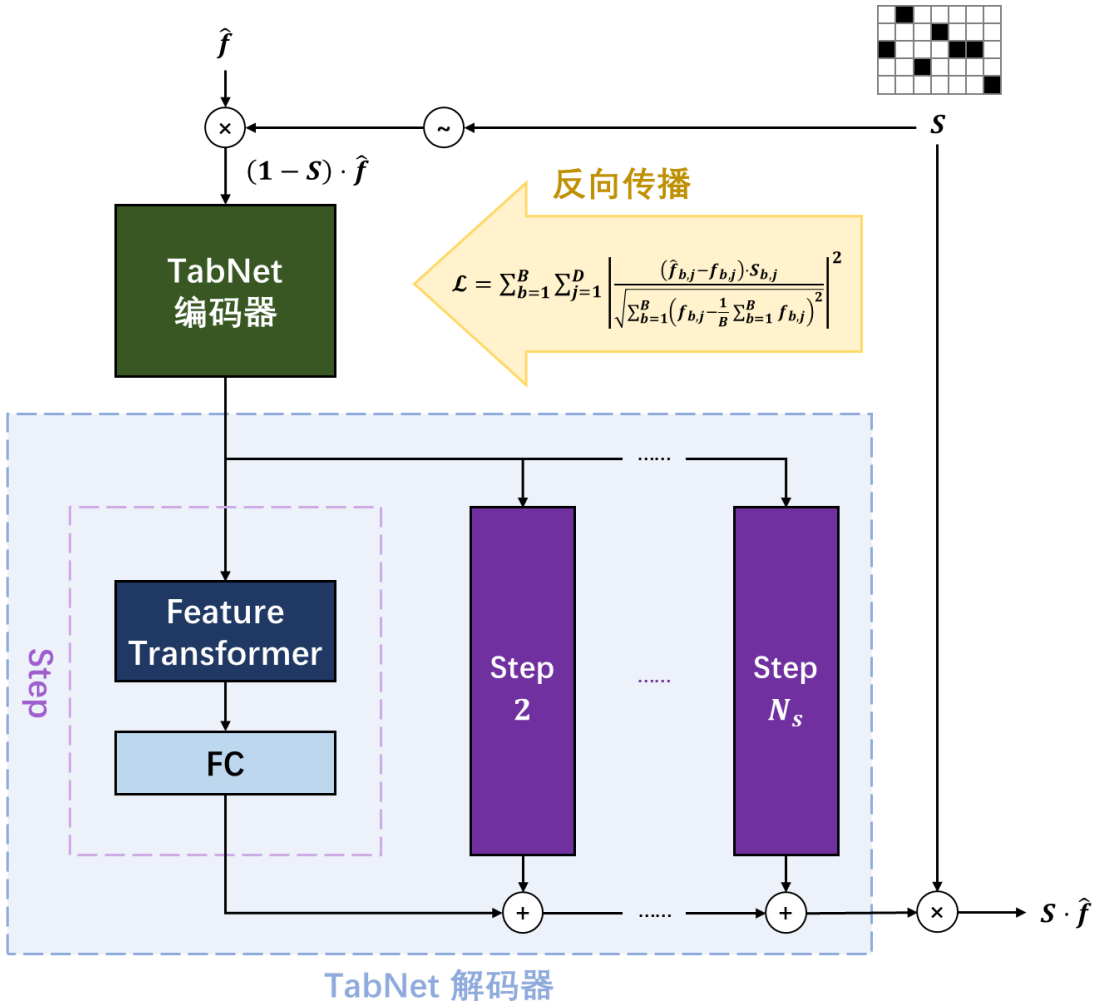

预训练机制

数据集： HCRL Car-Hacking Dataset、CAN-train-and-test

• 预测结果

数据集		准确率	检出率	误报率	F1 分数
HCRL	dos	100.00	100.00	0	100.00
	fuzzy	100.00	100.00	0	100.00
	gear	100.00	100.00	0	100.00
	rpm	100.00	100.00	0	100.00
	overall	100.00	100.00	0	100.00
CTT	dos	100.00	100.00	0	100.00
	fuzzy	99.97	99.00	0.02	97.89
	speed	100.00	100.00	0	100.00
	rpm	100.00	100.00	0	100.00
	double	99.99	100.00	0.01	95.70
	triple	97.73	100.00	2.41	82.83
	overall	99.97	100.00	0.03	99.00

• 对比实验

模型	HCRL@fuzzy				CTT			
	Acc	DR	FPR	F1	Acc	DR	FPR	F1
MLP	97.70	97.77	2.31	91.61	97.88	32.75	1.39	25.50
SVM	99.99	99.97	0.00	99.93	97.20	32.75	2.07	20.62
CatBoost	99.99	99.95	0.00	99.65	99.96	96.27	0.01	97.81
XGBoost	100.00	99.99	0.00	100.00	99.96	96.95	0.01	98.18
ECF-IDS[39]	99.98	99.96	0.02	99.98	99.96	99.84	0.02	98.94
SCANet	**100.00**	**100.00**	**0**	**100.00**	**99.97**	**100.00**	**0.03**	**99.00**

• 消融实验

数据集	SCANet				w/o 时空选择			
	Acc	DR	FPR	F1	Acc	DR	FPR	F1
HCRL@fuzzy	100.00	100.00	0	100.00	99.98	99.96	0.02	99.92
CTT@fuzzy	99.97	99.00	0.02	97.89	99.95	98.08	0.04	95.91

数据集	w/o 置信度机制				w 置信度机制，w/o 置信度矫正			
	Acc	DR	FPR	F1	Acc	DR	FPR	F1
HCRL@fuzzy	99.99	99.98	0.00	99.97	100.00	100.00	0	100.00
CTT@fuzzy	99.98	97.74	0.00	98.61	99.99	98.74	0.00	99.16
CTT@double	99.87	0	0	0	99.95	100.00	0.05	82.79
CTT@triple	92.01	0	0	0	93.44	100.00	6.94	62.58

• 可解释性分析

- 时空选择

攻击方式	w_{att} 平均取值
dos	65.56
fuzzy	46.41
gear	58.74
rpm	54.45

- 特征重要性

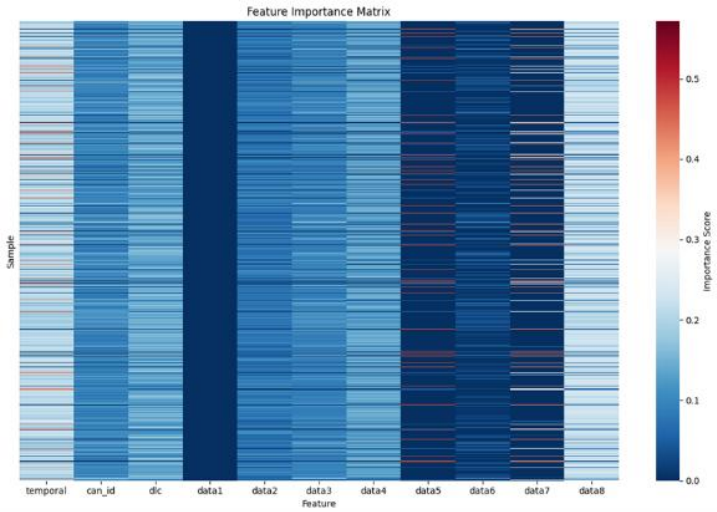

HCRL@dos

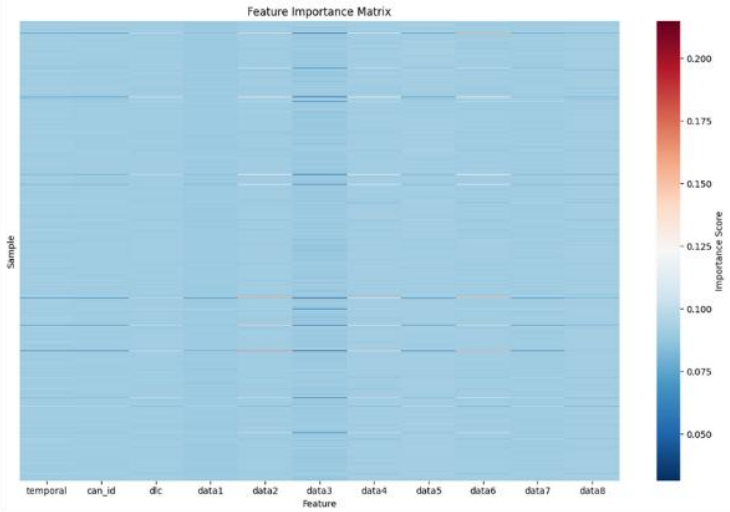

HCRL@fuzzy

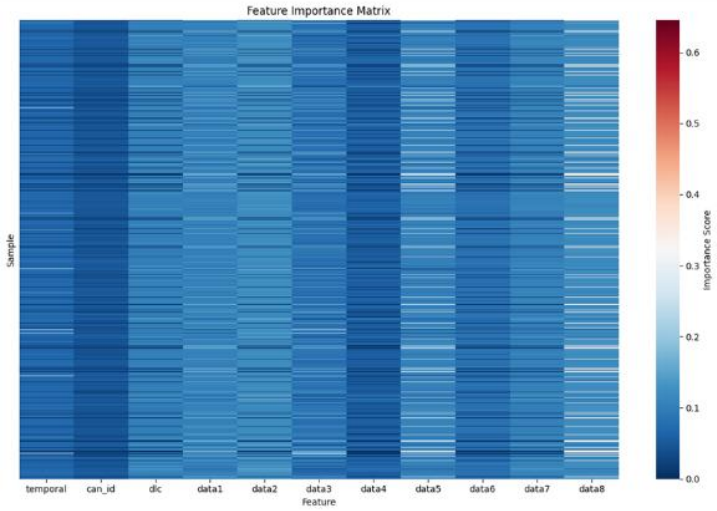

HCRL@gear

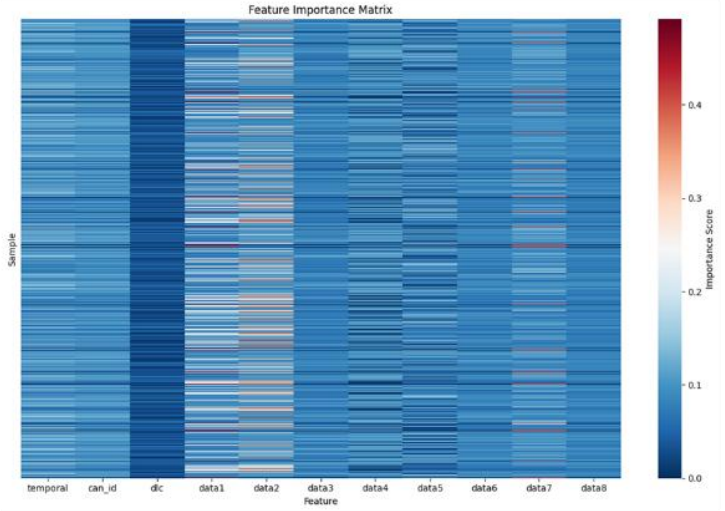

HCRL@rpm

- **预测置信度分布**

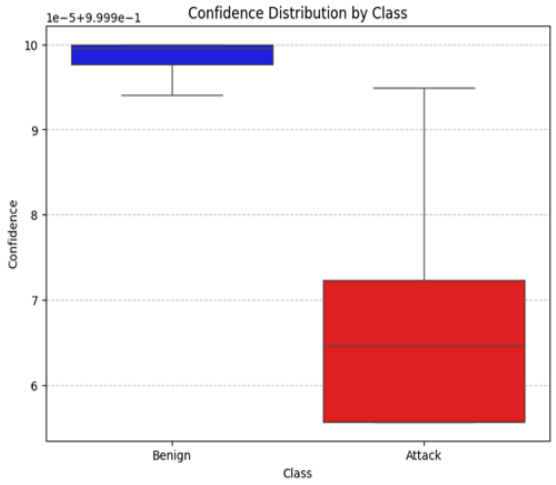

CTT@dos

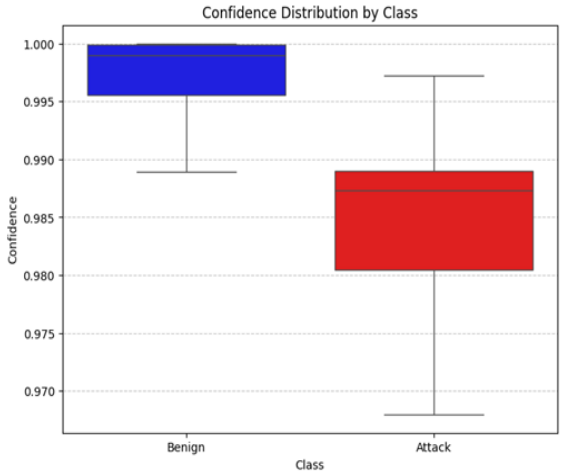

CTT@fuzzy

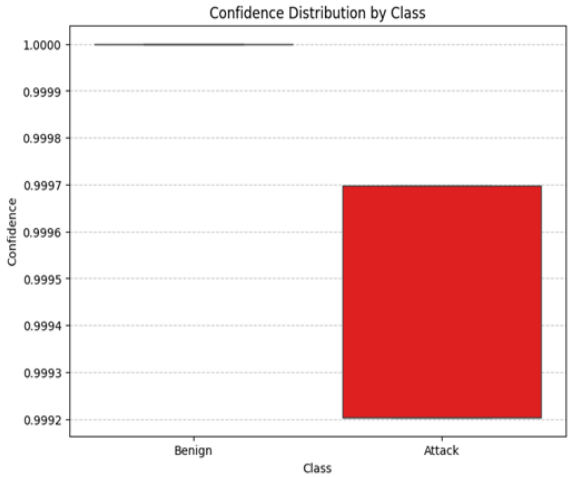

CTT@double

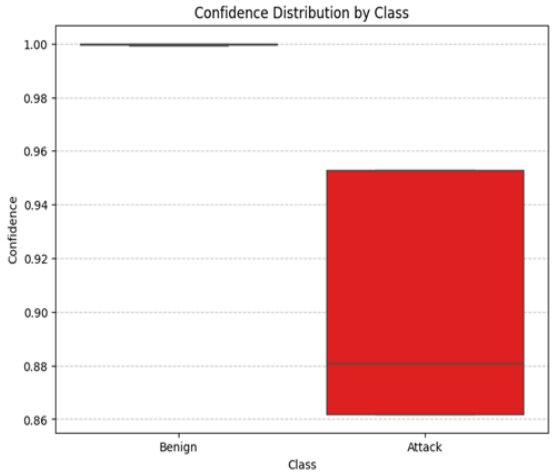

CTT@triple

- **本文工作**
  - 提出**SCANet**：基于时空选择与置信度反馈的CAN流量IDS框架
  - 设计了一种灵活的**时空特征提取与融合**方案
  - 设计了一种**可解释的检测器**
  - 使用“预训练-微调”的**训练架构**，并对训练模式做出优化
  - 在2组公用CAN流量数据集中共10个子任务中进行了**全面的实验**
    结果表明了该方案的可行性，以及在现有基础模型与方案中的出色表现

- **展望**
  - 探究更鲁棒的全局时序特征提取方法对检测的增益效果
  - 迁移到IoV环境下进行检测
  - 采用更精确的方法，用于系统性地评估模型可解释性
  - 结合人机协同思想，允许人工对IDS预测结果真实性进行反馈

感谢聆听

欢迎老师批评与指正!

答辩人：**李宏宇**
指导老师：**王一丰**
2025.5.19